AEM - Tema 6 - Regresión y Clasificación mediante KNN. Trabajo de evaluación.

Jerónimo Carranza Carranza 20 de febrero de 2017

Contents

1	Conjunto de datos para el estudio	2				
2	Problema de Clasificación					
3	Problema de Regresión	7				
	3.1 kNN ponderado	7				
	3.2 kNN aleatorio	8				
	3.3 Estudio comparativo	9				

1 Conjunto de datos para el estudio

• Dimensiones: n=4000 casos, m=42 variables

Conjunto de datos: datawork.csv

##

\$ x37

: num

```
Variables: "clasobj" "varobj" "x01" "x02" .... "x40".
  • clasobj: variable nominal con modalidades: AA, BB, CC, DD.
    varobj: variable continua
  • atributos: x01, \ldots, x40.
datawork <- read.table("datawork.csv", header=TRUE, sep=";")</pre>
str(datawork)
                    4000 obs. of 42 variables:
   'data.frame':
    $ clasobj: Factor w/ 4 levels "AA", "BB", "CC", ...: 3 1 4 1 2 3 2 2 2 4 ...
                    12.6 25.1 28.8 26.6 18.5 ...
    $ varobj : num
##
                    0.64\ 0.7\ 0.45\ 0.15\ 0.7\ 0.37\ 0.36\ 0.5\ 0.5\ 0.64\ \dots
    $ x01
             : num
                    0.68 0.72 0.71 0.56 0.54 0.75 0.36 0.52 0.62 0.63 ...
    $ x02
             : num
##
    $ x03
                    25.1 16.1 57.8 17.8 17.5 ...
             : num
##
    $ x04
             : num
                    33.4 11 48.8 10 25.5 ...
##
                    103.2 38.3 148.2 30.3 82.4 ...
    $ x05
             : num
##
    $ x06
                    1.08 1.62 0.34 0.86 1.04 0.92 1.16 1.84 0.94 0.7 ...
             : num
##
    $ x07
             : num
                    80.3 57.3 174.5 57.4 57.5 ...
##
    $ x08
             : num
                    14.8 30.7 50.7 167.5 40.1 ...
##
    $ x09
             : num
                    18.09 17.13 2.72 23.09 1.7 ...
    $ x10
##
             : num
                    0.2 0.1 0.46 0.36 0.19 0.15 0.1 0.02 0.05 1.8 ...
##
    $ x11
                    2.78 1.73 4.81 2.94 2.22 ...
             : num
##
    $ x12
             : num 17.6 12 21.6 12.7 15.8 ...
##
    $ x13
             : num
                    18.9 15.5 21.3 12.9 17.4 ...
##
    $ x14
                    21 13 23.7 12 15.6 ...
             : num
                    18.7 12.6 20.5 12.8 14.6 ...
##
    $ x15
             : num
##
    $ x16
                    18.5 12.2 23.2 12.2 15.8 ...
             : num
##
   $ x17
                    18 12.7 21.1 12.9 17.4 ...
             : num
##
   $ x18
                    19.3 13.8 20.6 15.1 13.7 ...
             : num
##
    $ x19
             : num
                    18.6 12.1 21.9 12.6 16.7 ...
                    18.5 14.3 22.1 12.4 18.1 ...
##
    $ x20
             : num
             : num
    $ x21
                    18.5 10.4 24.9 12.6 15.6 ...
##
                    17.9 14.1 22.5 13.8 16.2 ...
    $ x22
             : num
##
    $ x23
             : num
                    18.3 11.5 22.1 14.2 15.2 ...
##
   $ x24
             : num
                    19.6 11.6 23.8 11.6 14.8 ...
    $ x25
                    18.7 12.3 22 13.3 15.7 ...
             : num
                    19.1 14.3 21.2 13.8 14.8 ...
##
    $ x26
             : num
##
    $ x27
                    20.7 16.9 20.7 15.5 14.5 ...
             : num
##
    $ x28
                    19.8 13.1 21.3 15 18.5 ...
             : num
##
    $ x29
                    0.61 0.54 0.32 0.46 0.3 0.25 0.15 0.78 0.11 0.16 ...
             : num
##
    $ x30
                    21 14 20 11 17 17 13 15 15 24 ...
             : int
##
   $ x31
                    145.5 83.3 189.1 91.3 119.3 ...
             : num
##
   $ x32
                    133.9 99.6 172.9 96.7 122.2 ...
             : num
##
    $ x33
             : num
                    147 94.1 171.7 108.3 112.8 ...
##
    $ x34
                    170 113 193 110 125 ...
             : num
##
   $ x35
             : num 142 92.1 168.1 103.9 124.9 ...
             : num 82.7 60.2 86.4 56.1 62.5 ...
    $ x36
```

50.07 37.2 9.47 24.95 12.78 ...

```
## $ x38 : num 397 226 515 245 345 ...
## $ x39 : num 393 276 451 262 296 ...
## $ x40 : num 415 313 505 314 358 ...
```

summary(datawork)

```
##
    clasobj
                  varobj
                                    x01
                                                     x02
   AA: 626
                   : 10.49
                                      :0.0700
                                                       :0.1300
              Min.
                               Min.
                                                Min.
              1st Qu.: 14.35
##
   BB:1315
                               1st Qu.:0.4000
                                                1st Qu.:0.5100
##
   CC:1372
              Median: 19.34
                               Median :0.5000
                                                Median :0.6000
                                                Mean
##
   DD: 687
              Mean
                     : 20.86
                               Mean
                                      :0.4989
                                                        :0.5977
              3rd Qu.: 25.48
##
                               3rd Qu.:0.6000
                                                3rd Qu.:0.7000
##
              Max.
                     :713.81
                               Max.
                                      :0.9400
                                                Max.
                                                        :0.9300
                                                           x06
##
         x03
                          x04
                                          x05
   Min. : 0.94
                            :-0.64
                                                      Min.
                     Min.
                                     Min. : 2.96
                                                              :0.080
   1st Qu.: 15.55
                     1st Qu.:21.56
                                     1st Qu.: 69.82
                                                      1st Qu.:0.660
##
   Median : 25.98
                     Median :29.54
                                     Median : 94.06
                                                      Median : 0.940
##
##
   Mean
                           :29.48
                                                      Mean
         : 30.42
                     Mean
                                     Mean
                                           : 93.91
                                                             :1.015
    3rd Qu.: 40.17
                     3rd Qu.:37.34
                                     3rd Qu.:117.63
                                                      3rd Qu.:1.270
##
   Max.
          :166.17
                           :62.67
                                            :194.56
                                                              :3.260
                     {\tt Max.}
                                     Max.
                                                      {\tt Max.}
##
         x07
                          x08
                                             x09
                                                                 x10
##
   Min. : 3.61
                     Min. :
                                 0.02
                                        Min.
                                             :
                                                    0.000
                                                            Min.
                                                                  : 0.0000
   1st Qu.: 51.86
                     1st Qu.:
                                 5.58
                                        1st Qu.:
                                                    1.147
                                                            1st Qu.: 0.1000
   Median: 83.12
##
                     Median :
                                21.86
                                        Median :
                                                    2.020
                                                           Median: 0.2500
##
   Mean : 96.34
                     Mean
                           : 162.95
                                        Mean
                                                    4.502
                                                            Mean : 0.4398
                                              :
   3rd Qu.:125.90
                                        3rd Qu.:
##
                     3rd Qu.:
                                80.82
                                                    3.480
                                                            3rd Qu.: 0.5700
   Max.
                            :68676.15
                                               :1097.640
##
          :502.70
                     Max.
                                        Max.
                                                            Max.
                                                                   :24.1800
##
         x11
                           x12
                                           x13
                                                            x14
##
         : 0.490
                      Min. :10.57
                                      Min. : 9.26
                                                      Min.
                                                             :10.21
   Min.
    1st Qu.: 2.158
                      1st Qu.:15.45
                                      1st Qu.:15.45
                                                      1st Qu.:15.40
##
   Median : 2.960
                      Median :17.66
                                      Median :17.60
                                                      Median :17.65
                      Mean :17.56
                                      Mean :17.58
##
   Mean
         : 4.197
                                                      Mean
                                                            :17.57
##
    3rd Qu.: 4.152
                      3rd Qu.:19.70
                                      3rd Qu.:19.70
                                                      3rd Qu.:19.69
          :688.530
                                      Max.
##
   Max.
                      Max.
                             :25.16
                                             :24.86
                                                      Max.
                                                              :24.64
##
         x15
                         x16
                                         x17
                                                         x18
##
   Min.
         :10.15
                    Min. : 9.65
                                    Min. :10.13
                                                    Min.
                                                           :10.47
##
   1st Qu.:15.42
                    1st Qu.:15.37
                                    1st Qu.:15.46
                                                     1st Qu.:15.43
   Median :17.58
                    Median :17.55
                                    Median :17.60
                                                    Median :17.62
##
   Mean :17.55
                    Mean :17.55
                                    Mean :17.57
                                                    Mean
                                                          :17.57
##
   3rd Qu.:19.68
                    3rd Qu.:19.66
                                    3rd Qu.:19.67
                                                    3rd Qu.:19.67
##
   Max.
          :24.73
                    Max.
                          :25.50
                                    Max. :25.15
                                                    Max. :25.22
##
         x19
                         x20
                                         x21
                                                         x22
##
   Min.
         :10.06
                    Min.
                          :10.26
                                    Min. : 9.59
                                                    Min. : 9.44
   1st Qu.:15.44
##
                    1st Qu.:15.37
                                    1st Qu.:15.45
                                                     1st Qu.:15.39
##
   Median :17.61
                    Median :17.66
                                    Median :17.58
                                                    Median :17.63
##
   Mean
         :17.58
                    Mean
                         :17.58
                                    Mean
                                          :17.54
                                                    Mean
                                                          :17.57
##
    3rd Qu.:19.72
                    3rd Qu.:19.67
                                    3rd Qu.:19.63
                                                    3rd Qu.:19.71
          :25.08
##
   Max.
                           :24.95
                                    Max. :25.09
                                                           :24.99
                    Max.
                                                    Max.
##
        x23
                         x24
                                         x25
                                                         x26
                    Min. : 9.63
##
   Min. : 9.99
                                    Min. : 9.03
                                                    Min. : 9.89
##
   1st Qu.:15.47
                    1st Qu.:15.41
                                    1st Qu.:15.44
                                                     1st Qu.:15.39
##
   Median :17.59
                    Median :17.50
                                    Median :17.64
                                                    Median :17.59
   Mean :17.57
                    Mean :17.55
                                    Mean :17.55
                                                    Mean :17.59
   3rd Qu.:19.66
                    3rd Qu.:19.70
                                    3rd Qu.:19.75
                                                    3rd Qu.:19.73
##
```

```
Max. :25.29
                  Max. :25.15
                                 Max. :24.95
                                                Max. :25.05
##
   x27
                      x28
                                    x29
                                                x30
  Min. : 5.91
                  Min. : 7.81
##
                                 Min. :0.020
                                                Min. :10.00
   1st Qu.:15.23
                  1st Qu.:15.92
                                 1st Qu.:0.250
                                                1st Qu.:14.00
   Median :17.74
                  Median :18.41
                                 Median : 0.360
                                                Median :16.00
##
  Mean :17.78
                  Mean :18.47
                                 Mean :0.375
                                                Mean :16.76
   3rd Qu.:20.36
                  3rd Qu.:21.14
                                 3rd Qu.:0.490
                                                3rd Qu.:19.00
   Max. :47.94
                  Max. :28.27
                                 Max. :0.920
                                                Max. :29.00
##
##
        x31
                       x32
                                        x33
                                                      x34
##
  Min. : 75.25
                   Min. : 79.55
                                   Min. : 81.6
                                                  Min. : 83.37
   1st Qu.:119.00
                   1st Qu.:118.01
                                   1st Qu.:118.2
                                                  1st Qu.:132.24
## Median :135.91
                   Median :134.82
                                  Median :135.5
                                                  Median :151.30
  Mean :135.30
                   Mean :133.66
                                  Mean :134.2
                                                  Mean :150.74
##
   3rd Qu.:151.52
                                                  3rd Qu.:169.27
                   3rd Qu.:149.53
                                   3rd Qu.:150.0
##
##
   Max. :191.41
                   Max. :185.77
                                   Max. :189.7
                                                  Max. :241.19
##
        x35
                     x36
                                     x37
                                                      x38
##
   Min. : 75.3
                  Min. : 35.80
                                  Min. :-26.19
                                                  Min. :203.3
   1st Qu.:119.4
                  1st Qu.: 63.55
                                  1st Qu.: 10.10
                                                  1st Qu.:326.0
##
  Median :136.8
                  Median : 73.68
                                  Median : 19.36
                                                  Median :374.3
   Mean :136.5
                  Mean : 73.64
                                  Mean : 19.57
                                                  Mean :372.6
##
##
   3rd Qu.:154.4
                  3rd Qu.: 83.84
                                  3rd Qu.: 28.77
                                                  3rd Qu.:418.2
   Max. :197.3
                  Max. :110.56
                                  Max. :206.12
                                                  Max. :534.5
##
        x39
                      x40
                  Min. :226.3
##
   Min. :210.2
##
   1st Qu.:312.5
                  1st Qu.:349.1
  Median :357.7
                  Median :398.4
## Mean :355.8
                  Mean :397.5
   3rd Qu.:397.9
                  3rd Qu.:446.0
## Max. :493.2
                  Max. :553.8
```

2 Problema de Clasificación

Best k: 12

Determinación de un clasificador basado en kNN ponderado para la variable objetivo "clasobj" con los atributos x01...x40.

• Seleccionar aleatoriamente un conjunto test de tamaño n/3 y un conjunto de aprendizaje de tamaño 2n/3.

```
set.seed(123456789)
n = dim(datawork)[1]
test = sample(1:n, size = round(n/3), replace = FALSE, prob = rep(1/n, n))
datawork.test = datawork[test,-2] # no incluye la variable varobj
datawork.apre = datawork[-test,-2] # no incluye la variable varobj
# datawork.apre.summary = summary(datawork.apre)
# datawork.test.summary = summary(datawork.test)
# rbind(datawork.apre.summary,'----test-----',datawork.test.summary)
```

• Con el conjunto de aprendizaje, selecciona el mejor núcleo y el mejor k (entre 1 y 20) a través de validación cruzada.

 Aplicar el clasificador óptimo obtenido para clasificar los casos del conjunto test y obtener una medida del error de clasificación y la tabla de confusión asociada.

```
datawork.clasif.1.confusion = addmargins(table(predict(
   datawork.clasif.1,datawork.test), datawork.test$clasobj))
library(knitr)
kable(datawork.clasif.1.confusion, caption = "Matriz de Confusión")
```

Table 1: Matriz de Confusión

	AA	ВВ	CC	DD	Sum
\overline{AA}	205	0	1	7	213
BB	2	423	7	2	434
CC	1	3	434	1	439
DD	1	1	1	244	247
Sum	209	427	443	254	1333

A partir de la matriz de confusión pueden calcularse varias medidas del error de clasificación; la principal, la proporción de casos (test) incorrectamente clasificados.

```
sumNoError = 0
for (i in (1:4)){
   sumNoError = sumNoError + datawork.clasif.1.confusion[i,i]
}
pError = (1-sumNoError/dim(datawork.test)[1])
'Error de clasificación: '

## [1] "Error de clasificación: "
```

[1] 0.02025506

3 Problema de Regresión

3.1 kNN ponderado

[1] "Error Cuadrático Medio"

Determinación de un predictor basado en kNN ponderado para la variable objetivo "varobj" con los atributos x01...x40.

```
datawork.vtest = datawork[test,-1] # no incluye la variable clasobj
datawork.vapre = datawork[-test,-1] # no incluye la variable clasobj
```

• Con el conjunto de aprendizaje, selecciona el mejor núcleo y el mejor k (entre 1 y 20) a través de validación cruzada.

```
##
## Call:
## train.kknn(formula = varobj ~ ., data = datawork.vapre, kmax = 20, kernel = c("triangular", "rec
##
Type of response variable: continuous
## minimal mean absolute error: 1.752477
## Minimal mean squared error: 112.964
## Best kernel: optimal
## Best k: 2
```

 Aplicar el predictor óptimo obtenido para predecir los casos del conjunto test y obtener una medida del error de predicción.

```
datawork.kknn.predict = predict(datawork.kknn, datawork.vtest)
summary(datawork.kknn.predict)
##
     Min. 1st Qu. Median Mean 3rd Qu.
                                            Max.
    11.16 14.24
                   19.23
                           20.29
                                   25.42 147.80
datawork.kknn.error =
 sqrt ((datawork.vtest$varobj - datawork.kknn.predict)**2)
summary(datawork.kknn.error)
##
       Min. 1st Qu.
                        Median
                                    Mean 3rd Qu.
## 0.000238 0.325400 0.685600 1.637000 1.480000 27.720000
"Error Cuadrático Medio"
```

```
datawork.kknn.ECM = mean(datawork.kknn.error**2)
datawork.kknn.ECM

## [1] 12.16573

# datawork.kknn.ECM =
# sum(datawork.kknn.error**2)/dim(datawork.vtest)[1]
# datawork.kknn.ECM

# test_reg = lm(datawork.vtest$varobj ~ datawork.kknn.predict)
# summary(test_reg)
```

3.2 kNN aleatorio

Determinación de un predictor basado en kNN aleatorio para la variable objetivo "varobj" con los atributos x01...x40.

```
library(rknn)
## Loading required package: gmp
##
## Attaching package: 'gmp'
## The following objects are masked from 'package:base':
##
       %*%, apply, crossprod, matrix, tcrossprod
datawork.vapre.norm = data.frame(normalize.softmax(datawork.vapre))
datawork.vtest.norm = data.frame(normalize.softmax(datawork.vtest))
# Elección de r (número de clasificadores / regresores)
p = (dim(datawork.vapre)[2]-1)
datawork.vapre.r.binomial =
  r(p,m = floor(sqrt(p)),eta = 0.99,method = "binomial")
datawork.vapre.r.poisson =
  r(p,m = floor(sqrt(p)),eta = 0.99,method = "poisson")
datawork.vapre.r.binomial
## [1] 52
datawork.vapre.r.poisson
```

[1] 52

```
# Aplicación rkNNReg
datawork.rknn =
 rknnReg(datawork.vapre.norm, datawork.vtest.norm,
         y=datawork.vapre$varobj, k = 1, r=60, seed=123456789
datawork.rknn$k
## [1] 1
datawork.rknn$n
## NULL
datawork.rknn$mtry
## [1] 6
datawork.rknn.error =
  sqrt ((datawork.vtest$varobj - datawork.rknn$pred)**2)
summary(datawork.rknn.error)
##
      Min. 1st Qu. Median
                              Mean 3rd Qu.
                                              Max.
## 0.0000 0.3632 0.8272 1.3760 1.4820 38.3700
"Error Cuadrático Medio"
## [1] "Error Cuadrático Medio"
datawork.rknn.ECM = mean(datawork.rknn.error**2)
datawork.rknn.ECM
```

[1] 8.453614

3.3 Estudio comparativo

Realizar un estudio comparativo entre ambos resultados

Se comparan mediante el error (test) cuadrático medio de cada modelo; kknn y rknn.

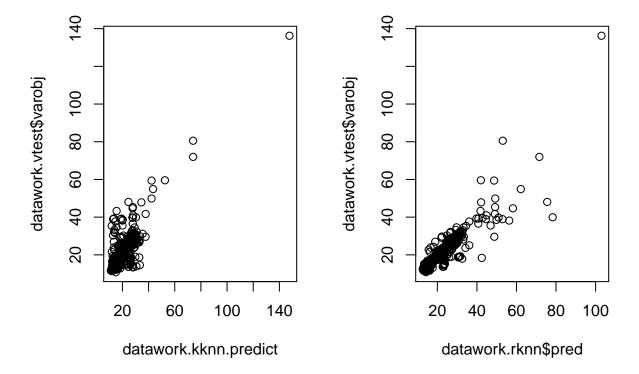
Table 2: Comparación de Modelos

	kknn	rknn
Error Cuadrático Medio	12.16573	8.453614

Los resultados de ECM muestran que el modelo rknn proporciona predicciones más ajustadas a los valores de la variable respuesta que el modelo kknn.

Se representa finalmente las predicciones de cada modelo frente a los valores observados de la variable respuesta en el conjunto test.

```
par(mfrow = c(1,2))
plot(datawork.kknn.predict,datawork.vtest$varobj)
plot(datawork.rknn$pred,datawork.vtest$varobj)
```



```
par(mfrow = c(1,1))
```